



MÓDULO II

Aprendizaje Supervisado

Curso:

Machine Learning Supervisado

Machine Learning Supervisado

Sesión 01: Ingeniería de ML y Baselines Robustos

De "Correr Celdas" a Construir Software Predictivo



BLOQUE 0

Conociéndonos

Tu Profesor: Jordan King Rodriguez Mallqui

Formación Académica

- **Cand. PhD** en Ciencias e Ingeniería Estadística (UNI)
- Ms Data Science (UPC),
- Bch Ingeniería Estadística (UNI)

Experiencia Profesional

- **Senior Manager** Pricing Analytics & Data en **BBVA**
- Lidera equipo de Data Scientists y Data Specialists
- Modelos creados en área comercial, riesgos, finanzas. Sector público y privado

Docencia

- Profesor en **UNI** (Centro de Formación Continua)
- Cursos: Fundamentos de Ciencia de Datos, Power BI, Data Storytelling, Machine Learning

Intereses de Investigación

- Estimación de precios
- Productos financieros
- Datos georeferenciados

Conectemos

Contacto

- **Email:** jrodriguezm216@gmail.com
- **Web:** jordandataexpert.com

Redes Profesionales

- **GitHub:** github.com/JordanKingPeru
- **LinkedIn:** linkedin.com/in/jordan-rodriguez-peru

Filosofía del Curso

"No enseño a correr celdas, enseño a construir sistemas de ML que funcionan en producción."

Mi Compromiso

- Casos reales de distintas industrias
- Código que puedes usar mañana en tu trabajo
- Feedback continuo y soporte

¿Y ustedes?

Cuéntanos en el chat:

1. **Nombre** y empresa/universidad
2. **¿Qué experiencia tienes con ML?** (Ninguna / Básica / Intermedia)
3. **¿Qué problema quieres resolver?** (Clasificación de clientes, predicción de ventas, etc.)

Agenda de Hoy

Bloque	Tema	Duración
1	 Mapa del Curso, Anatomía de Proyecto y Algoritmo	25 min
2	 Antes de Modelar: EDA y Calidad de Datos	20 min
3	 Anti-Patterns +  Pipelines de Scikit-Learn	30 min
4A	 Regresión Lineal (intuición → métricas → condiciones)	25 min
4B	 Regresión Logística (de valores a probabilidades)	30 min
	Break	15 min
5	 Validación Honesta: CV y Sesgo-Varianza	15 min
6	 Data Leakage +  Hands-On del Pipeline	40 min

BLOQUE 1

El Mapa: Curso, Proyecto y Algoritmo

¿Qué aprenderemos en este curso?

Algoritmos que dominaremos:


-  Regresión Logística (Baseline)
-  Árboles de Decisión (CART)
-  Random Forest (Bagging)
-  **XGBoost / LightGBM** (SOTA)
-  SVM (Casos específicos)
-  KNN (Imputación + Clasificación)
-  Naive Bayes (Texto)
-  Redes Neuronales (Intro)

Habilidades de Ingeniero:

-  Pipelines reproducibles
-  Optimización con Optuna
-  Métricas de negocio (Profit Curves)
-  Interpretabilidad (SHAP)
-  Despliegue (Streamlit/FastAPI)




Roadmap del Curso



Cada sesión **construye sobre la anterior**: hoy sentamos las bases de ingeniería (pipelines, baselines, fugas) sobre las que descansará todo lo demás.

Anatomía de un Proyecto de ML

"El algoritmo es solo el 20%. El otro 80% es todo lo que lo rodea."



Hoy (Sesión 01) cubrimos los pasos 2 → 6. El caso integrador final (M07) recorre los 8 de punta a punta.

Taxonomía del Aprendizaje Supervisado




En este curso: foco en **clasificación binaria** (riesgo, fraude, churn), con regresión como cimiento conceptual.

¿Cómo "aprende" un algoritmo?

La analogía del estudiante:

-  **Datos de entrenamiento** = el libro de texto ($X \rightarrow y$).
-  **Objetivo** = aprobar el examen (predecir bien casos nuevos).
- El modelo busca una **función $f(X)$** que prediga y .


"Un estudiante que busca patrones en los datos para responder preguntas nuevas."





Intuición: minimizar el error

Gradiente descendente: pasitos cuesta abajo hacia el menor error



Gradiente descendente: el algoritmo da "pasitos" en la dirección que más reduce el error, hasta llegar al mínimo.

Cada iteración de entrenamiento = un paso cuesta abajo.

Los parámetros: lo que el modelo aprende

En regresión lineal/logística, los parámetros son los **coeficientes (β)**:

$$\hat{y} = \beta_0 + \beta_1x_1 + \beta_2x_2 + ... + \beta_nx_n$$

Símbolo	Nombre	Qué representa
β_0	Intercepto	Valor base cuando todas las X = 0
$\beta_1, \beta_2...$	Pesos	Cuánto influye cada variable
$x_1, x_2...$	Features	Los datos de entrada
$\hat{y}$	Predicción	Lo que el modelo predice

El entrenamiento = encontrar los β que **minimizan el error** (la figura anterior).

Plantilla: "Anatomía de un algoritmo"

Cada vez que estudiemos un algoritmo en profundidad, lo recorreremos con **la misma estructura**. Así sabes siempre qué preguntar de un modelo nuevo:

1

Intuición

¿Qué hace, en una frase?

2

Matemática

La ecuación y cómo aprende.

3

Condiciones

Supuestos y cuándo es válido.

4

Métricas

Cómo se mide su desempeño.

5

Código

Implementación en sklearn.

6

Interpretación

Qué significan los resultados.

7

Cuándo usar

Fortalezas y límites.

★

Comparar

vs. el baseline.

🤔 ¿Cuándo usar cada algoritmo?



Regla de oro: empieza siempre con *Regresión Logística* como **baseline**. Si tu modelo complejo no le gana, algo está mal.

Matriz de cobertura de algoritmos

Tema	Nivel de Profundidad	Sesión
Regresión Lineal/Logística	●●● Alto (con Pipelines)	01
Árboles / Random Forest	●●●● Muy Alto	02
XGBoost / LightGBM / CatBoost	●●●● Muy Alto	02
SVM	●● Medio (Concepto y uso básico)	02
KNN	●● Medio	02
Naive Bayes	● Rápido (Mención y ejemplo)	02
Redes Neuronales (MLP)	●● Medio	04
Métricas / Validación	●●●● Muy Alto (Business + Tech)	03-04

Bibliografía del Curso (Referencias APA)

Libros Principales:

- Géron, A. (2022). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow* (3rd ed.). O'Reilly Media.
- Provost, F., & Fawcett, T. (2013). *Data Science for Business*. O'Reilly Media.
- Molnar, C. (2022). *Interpretable Machine Learning* (2nd ed.). Leanpub.
<https://christophm.github.io/interpretable-ml-book/>

Recursos Adicionales:

- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning* (2nd ed.). Springer.
- Thakur, A. (2020). *Approaching (Almost) Any Machine Learning Problem*. Amazon.
- Zheng, A., & Casari, A. (2018). *Feature Engineering for Machine Learning*. O'Reilly Media.


BLOQUE 2

Antes de Modelar: EDA y Calidad de Datos

🔍 ¿Por qué EDA primero?

"Horas de EDA ahorran semanas de depurar un modelo que nunca debió entrenarse."

EDA: conocer los datos antes de modelar



Antes de tocar un modelo: **distribuciones** (¿sesgo, colas?), **outliers** (boxplots), y **diferencias por clase** (¿la variable separa buenos de malos?). Esto decide qué transformaciones y qué features tienen sentido.


Correlación y multicolinealidad

¿Por qué importa?

- Variables muy correlacionadas **inflan los coeficientes**.
- El modelo "no sabe a cuál creerle".
- Se detecta con el **mapa de correlación** y el **VIF** (regla: $VIF > 5$ = alerta).

Qué hacer:

- Eliminar una redundante, o combinarlas (ratio).
- O usar **regularización** (lo veremos en logística).



☛ **Datos faltantes: no todos son iguales**

Tipo	Qué significa	Riesgo
MCAR (al azar)	El faltante no depende de nada	Bajo: imputar es seguro
MAR (condicional)	Depende de otra variable observada	Medio: imputar condicionando
MNAR (informativo)	El faltante depende del propio valor	Alto : el faltante ES información

⚠ **Cuándo imputar es peligroso:**

- Un nulo en `ingreso` que aparece solo en morosos → **MNAR**: imputar la media **borra la señal**. Mejor crear una bandera `ingreso_faltante`.
- Imputar con la media de **todo** el dataset = **data leakage** (lo veremos en el Bloque 6).

Regla: primero **entiende por qué falta**, luego decide cómo imputar.

BLOQUE 3

Anti-Patterns y Pipelines

❌ El Código "Spaghetti" que Todos Hemos Escrito

```
# 🚩 ANTI-PATTERN: El notebook caótico
df = pd.read_csv('data.csv')
df.fillna(0) # Sin asignar, no hace nada
df = df.dropna() # Perdemos datos sin criterio

# Encoding manual que explota en producción
df = pd.get_dummies(df)

# ¿Media de TODO el dataset? 🙄 Data Leakage...
df['income'] = df['income'].fillna(df['income'].mean())

# Split al final, después de contaminar
X_train, X_test = train_test_split(df)
```

Pregunta: *¿Qué pasa si llega un cliente nuevo mañana con una categoría que no existía?*


Los 6 Pecados Capitaes del ML

#	Anti-Pattern	Consecuencia
1	Data Leakage	Accuracy 99% → 60% en producción
2	Código Irreproducible	"En mi máquina funciona..."
3	Encoding Frágil	Crash cuando llega categoría nueva
4	Olvidar Escalar	Modelo no converge o tarda horas
5	IDs como Features	El modelo memoriza índices
6	Evaluar en Train	Overfitting disfrazado de éxito

 **Lectura Recomendada:** Sculley, D. et al. (2015). *Hidden Technical Debt in Machine Learning Systems*. NeurIPS.

✓ La Solución: Pipelines

"Un tubo donde entran datos crudos y sale una predicción."



Ventajas:

1. **Modular:** cada paso es intercambiable.
2. **Seguro:** evita Data Leakage (aprende solo del train).
3. **Serializable:** se guarda en un solo archivo `.joblib`.
4. **Productivo:** `pipeline.predict(nuevo_cliente)` y listo.

Componentes del Pipeline

Imputación (Nulos)

```
# Básico (Estadística simple)
SimpleImputer(strategy='median')

# Pro (Vecinos cercanos)
KNNImputer(n_neighbors=5)

# Expert (Iterativo/MICE)
IterativeImputer()
```

Encoding (Categorías)

```
# Básico (Explosión de columnas)
OneHotEncoder(handle_unknown='ignore')

# Pro (Usa el target)
TargetEncoder() # nativo de sklearn

# Expert (Estadístico)
WoEEncoder() # Weight of Evidence
```

 **Warning:** OneHotEncoder con 500 categorías = 500 columnas nuevas.

Feature Engineering: crear señal

Transformaciones numéricas

```
# Domesticar colas largas (ingreso, precios)
df['log_ingreso'] = np.log1p(df['ingreso'])

# Capturar no-linealidad (curvatura)
PolynomialFeatures(degree=2)

# Ratios con sentido de negocio
df['ratio_deuda'] = df['deuda'] / df['ingreso']
```

Interacciones

```
# El efecto de X depende de Z
df['edad_x_ingreso'] = df['edad'] * df['ingreso']
```

Un buen *feature* suele aportar más que un modelo más complejo.

Regla: las transformaciones se calculan **dentro del Pipeline** (fit solo en train), nunca antes del split.

abc Encoding de categóricas: ¿cuál uso?

Encoder	Cómo funciona	Cuándo	Cuidado
OneHot	1 columna por categoría	Pocas categorías (<10-15)	Explota con alta cardinalidad
Ordinal	Asigna enteros 0,1,2...	Categorías con orden (bajo/medio/alto)	No usar si no hay orden real
Target	Reemplaza por la media del target	Alta cardinalidad	Riesgo de leakage → usar cross-fitting
WoE	log(odds) por categoría	Scoring crediticio / regulado	Requiere target binario

En el taller usamos **TargetEncoder** (con cross-fitting interno) para las categóricas de alta cardinalidad.

¿Qué modelos necesitan escalado?

✅ Sí necesitan escalar

- Regresión Lineal/**Logística** (convergencia)
- **SVM**, **KNN** (basados en distancia)
- Redes Neuronales
- Cualquier modelo con **regularización**

❌ No lo necesitan

- Árboles de Decisión
- Random Forest
- XGBoost / LightGBM

(las particiones por umbral son invariantes a la escala)

Por eso el escalado va **dentro** del Pipeline: solo afecta a los modelos que lo requieren, y nunca contamina el test.



ColumnTransformer: El Router

```
from sklearn.compose import ColumnTransformer
from sklearn.pipeline import Pipeline

# Rutas diferentes para diferentes tipos de datos
preprocessor = ColumnTransformer([
    ('num', Pipeline([
        ('imputer', SimpleImputer(strategy='median')),
        ('scaler', StandardScaler())
    ]), numeric_features),

    ('cat', Pipeline([
        ('imputer', SimpleImputer(strategy='constant', fill_value='missing')),
        ('encoder', TargetEncoder())
    ]), categorical_features)
])

# Pipeline Final
model = Pipeline([
    ('preprocessor', preprocessor),
    ('classifier', LogisticRegression())
])
```



BLOQUE 4A

Regresión Lineal: el modelo más simple

Plantilla:  Intuición ·  Matemática ·  Métricas ·  Condiciones

Intuición: ¿qué es la Regresión Lineal?

"Encontrar la mejor línea recta que pase cerca de todos los puntos."





Matemática: la ecuación de la recta

Ecuación Simple (1 variable):

$$\hat{y} = \beta_0 + \beta_1 x$$

Ecuación Múltiple (n variables):

$$\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_n x_n$$

Interpretación de los Parámetros:

Parámetro	Significado
β_0	Intercepto - Valor de y cuando x=0
β_1	Pendiente - Cuánto cambia y por cada unidad de x

Ejemplo:

$$\text{Precio} = 50,000 + 1,200 \times \text{metros}^2$$

"Una casa de 0 m² cuesta \$50,000 (base) y cada m² adicional suma \$1,200."



¿Cómo encuentra la mejor línea? (OLS)


Método de Mínimos Cuadrados Ordinarios (OLS)

Objetivo: minimizar la suma de los errores al cuadrado.

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

¿Por qué al cuadrado?

1. Elimina signos negativos
2. Penaliza más los errores grandes
3. Tiene solución matemática cerrada (única)





Código: Regresión Lineal en Scikit-Learn

```
from sklearn.linear_model import LinearRegression
from sklearn.model_selection import train_test_split
from sklearn.metrics import root_mean_squared_error, r2_score

# Datos
X = df[['metros_cuadrados', 'habitaciones', 'antiguedad']]
y = df['precio']

# Split
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

# Entrenar
modelo = LinearRegression()
modelo.fit(X_train, y_train)


# Evaluar (¡en TEST, no en train!)
y_pred = modelo.predict(X_test)
print(f"R² Score: {r2_score(y_test, y_pred):.3f}")
print(f"RMSE: {root_mean_squared_error(y_test, y_pred):.2f}")
```

🔍 Interpretación de Coeficientes

```
print(f"β₀: {modelo.intercept_:.0f}")  
for f, c in zip(X.columns, modelo.coef_):  
    print(f"{f}: {c:,.2f}")
```

Intercepto (β_0): 45,000
metros_cuadrados: +1,250
habitaciones: +8,500
antigüedad: -1,200

"Cada m² suma \$1,250; cada año de antigüedad resta \$1,200."



Métricas: ¿qué tan bueno es el modelo?

Métrica	Fórmula	Cuándo usarla
MSE	$\frac{1}{n} \sum (y - \hat{y})^2$	Optimización (penaliza outliers)
RMSE	$\sqrt{MSE}$	Reportar: error en unidades de y
MAE	$\frac{1}{n} \sum y - \hat{y} $	Cuando hay outliers (más robusta)
R ²	$1 - \frac{SS_{res}}{SS_{tot}}$	% de varianza explicada (0-1)
R ² ajustado	penaliza n° de features	Comparar modelos con distinto n° de variables

Guía práctica:


- $R^2 = 0.85 \rightarrow$ el modelo explica el 85% de la variabilidad.
- $RMSE = \$15,000 \rightarrow$ en promedio nos equivocamos por \$15,000.
- $RMSE \gg MAE \rightarrow$ hay errores grandes (outliers) que conviene revisar.

🔧 MAE vs RMSE: el efecto de un outlier

Ambas miden el error promedio, pero **RMSE eleva al cuadrado** antes de promediar → un solo error grande pesa muchísimo más.

- **MAE**: robusto, trata todos los errores igual.
- **RMSE**: sensible a outliers; úsalo si los errores grandes son **caros** para el negocio.

Si ves **RMSE** $\gg$ **MAE**, ve a buscar esos pocos errores enormes.



Condiciones: supuestos de la Regresión Lineal

Para que el modelo (y la interpretación de sus β) sea válido, se asume:

Supuesto	Qué significa	Cómo verificar
Linealidad	Relación lineal entre X e y	Gráfico de dispersión
Homocedasticidad	Varianza del error constante	Residuos vs predicciones
Independencia	Errores no correlacionados	Durbin-Watson test
Normalidad	Errores siguen distribución normal	QQ-plot
No multicolinealidad	Features no muy correlacionadas	VIF < 5

 **En la práctica:** muchos problemas reales violan estos supuestos. Por eso usamos **regularización** o modelos más robustos (árboles). Validar supuestos te dice **cuánto confiar** en los coeficientes.

De Regresión Lineal a Logística

El Problema:

Regresión Lineal	Regresión Logística
Predice valores continuos	Predice probabilidades
Salida: $-\infty$ a $+\infty$	Salida: 0 a 1
Ejemplo: Precio de casa	Ejemplo: ¿Cliente pagará? (Sí/No)

Lineal:

$y = \beta_0 + \beta_1 x$

(puede dar -50 o 150)

Logística:

$P(y=1) = \sigma(\beta_0 + \beta_1 x)$

(siempre entre 0 y 1)

↓

La función σ (sigmoide) "aplasta" la salida al rango [0, 1].

BLOQUE 4B

Regresión Logística: de valores a probabilidades

Historia y Contexto

Orígenes:

- **1838:** Pierre-François Verhulst introduce la curva logística para modelar crecimiento poblacional.
- **1958:** David Cox formaliza la Regresión Logística para clasificación binaria.
- **Hoy:** sigue siendo el **estándar de oro** en banca, salud y seguros por su interpretabilidad.

¿Por qué sigue vigente?

-  **Regulaciones (Basilea III, FDA):** exigen modelos explicables.
-  **Baseline imbatible:** si tu modelo complejo no gana al LogReg, algo está mal.
-  **Probabilidades calibradas:** directamente interpretables.

 Hosmer, D. W., Lemeshow, S., & Sturdivant, R. X. (2013). *Applied Logistic Regression* (3rd ed.). Wiley.



Matemática: la función Sigmoide


Queremos predecir la **probabilidad** de un evento binario (Sí/No). Pero las probabilidades están entre 0 y 1, y la recta no respeta esos límites.

Solución — la sigmoide:

$$P(Y = 1|X) = \sigma(z) = \frac{1}{1 + e^{-z}}$$

donde z es la combinación lineal:

$$z = \beta_0 + \beta_1 x_1 + \dots + \beta_n x_n$$



Odds y Log-Odds (Logit)

Odds (Momios):


$$\text{Odds} = \frac{P(Y = 1)}{P(Y = 0)} = \frac{P}{1 - P}$$

Ej: si $P=0.8$, Odds = 4 → "4 a 1 a favor".

Log-Odds (Logit):

$$\text{logit}(P) = \ln\left(\frac{P}{1 - P}\right) = \beta_0 + \beta_1 x_1 + \dots$$

¡Esta es la ecuación clave!



1 2 3 4 ¿Por qué usamos Log-Odds?

Probabilidad (P)	Odds (P/(1-P))	Log-Odds (ln)
0.01	0.01	-4.60
0.10	0.11	-2.20
0.50	1.00	0.00
0.90	9.00	+2.20
0.99	99.0	+4.60

Ventaja: el Log-Odds va de $-\infty$ a $+\infty$, igual que una recta de regresión lineal! Esto permite **modelar probabilidades con una ecuación lineal**.

Interpretación de Coeficientes (β)

Odds Ratio (OR):

$$OR = e^{\beta}$$


Coeficiente (β)	Odds Ratio (e^{β})	Interpretación
$\beta = 0$	OR = 1.0	Variable sin efecto
$\beta = 0.5$	OR = 1.65	↑ 65% en odds por unidad
$\beta = -0.3$	OR = 0.74	↓ 26% en odds por unidad
$\beta = 1.0$	OR = 2.72	↑ 172% en odds por unidad

Lectura: "Por cada unidad de aumento en X , los odds del evento se multiplican por OR."


Ejemplo Real: Credit Scoring

Variable	β	OR (e^β)
Edad (años)	-0.02	0.98
Tiene hipoteca	-0.40	0.67
Meses último atraso	0.08	1.08
Deuda / Ingreso	1.50	4.48

"Un cliente con ratio Deuda/Ingreso alto tiene 4.5× más probabilidad de caer en default."



Dirección e impacto de los coeficientes



Ejemplo (credit scoring): la edad suele tener $\beta < 0$ (protector); el número de atrasos, $\beta > 0$ (riesgo).

Condiciones de la Regresión Logística

A diferencia de la lineal, **no** exige normalidad ni homocedasticidad de los errores, pero sí:

Supuesto	Qué significa
Linealidad en el log-odds	La relación lineal es con <code>logit(P)</code> , no con P directamente
Independencia	Las observaciones no están correlacionadas entre sí
No multicolinealidad	Igual que en lineal (VIF) — afecta la estabilidad de los β
Tamaño muestral	Suficientes casos del evento raro (regla práctica: ≥ 10 por variable)

Si la relación con el log-odds no es lineal, ahí es donde brillan los **árboles** (Sesión 02).


Regularización: Ridge, Lasso y ElasticNet

¿Por qué regularizar?

- **Multicolinealidad:** variables correlacionadas inflan los coeficientes.
- **Overfitting:** muchas variables → el modelo memoriza ruido.

Tipo	Penalización	Efecto	Uso típico
Ridge (L2)	$\lambda \sum \beta_j^2$	Encoge coeficientes	Multicolinealidad
Lasso (L1)	$\lambda \sum \beta_j $	Lleva β a cero	Selección automática
ElasticNet	L1 + L2	Combinación	Mejor de ambos mundos

Regularización: Ridge encoge los coeficientes; Lasso lleva algunos a CERO (selección automática)



Función de Costo: Log-Loss (Cross-Entropy)

El modelo encuentra los β que **minimizan** el error de predicción:

$$\mathcal{L} = -\frac{1}{N} \sum_{i=1}^N [y_i \log(\hat{p}_i) + (1 - y_i) \log(1 - \hat{p}_i)]$$

Interpretación intuitiva:

Predicción ($\hat{p}$)	Realidad (y)	Penalización
0.9	1	Baja ✓
0.9	0	Alta ✗
0.1	0	Baja ✓
0.1	1	Alta ✗

El modelo aprende a dar **alta** probabilidad cuando $y = 1$ y **baja** cuando $y = 0$.

Hiperparámetros Clave en Scikit-Learn

```
from sklearn.linear_model import LogisticRegression

model = LogisticRegression(
    penalty='l2',           # Regularización: 'l1', 'l2', 'elasticnet', None
    C=1.0,                 # Inverso de  $\lambda$  (menor C = más regularización)
    class_weight='balanced', # Manejo de desbalance automático
    solver='liblinear',     # Optimizador: 'lbfgs', 'liblinear', 'saga'
    max_iter=1000,         # Iteraciones máximas para convergencia
    random_state=42        # Reproducibilidad
)
```

⚠️ Consejos Prácticos:

- **Desbalance de clases:** usa `class_weight='balanced'` o SMOTE
- **Muchas variables:** usa `penalty='l1'` para selección automática
- **No converge:** aumenta `max_iter` o escala los datos primero

Métricas de clasificación

Matriz de Confusión

	Pred. 0	Pred. 1
Real 0	TN	FP
Real 1	FN	TP

Métricas Derivadas

- **Accuracy:** $(TP + TN) / N \rightarrow$ ⚠️ engaña en desbalance
- **Precision:** $TP / (TP + FP) \rightarrow$ "de los positivos predichos, ¿cuántos acerté?"
- **Recall:** $TP / (TP + FN) \rightarrow$ "de los positivos reales, ¿cuántos detecté?"
- **F1:** media armónica de Precision y Recall
- **ROC-AUC:** desempeño independiente del umbral



Trade-off: subir Recall (detectar más fraudes) suele bajar Precision (más falsas alarmas). El balance lo decide el negocio.

🎯 Accuracy engaña: ROC vs Precision-Recall

El problema del desbalance

Con 99% de clientes buenos, un modelo que dice "*todos buenos*" tiene 99% accuracy... y es inútil.

- **ROC-AUC:** robusta, compara TPR vs FPR en todos los umbrales.
- **Precision-Recall:** mejor cuando la clase positiva es rara (fraude, default), porque se enfoca en los positivos.



🤔 ¿Cuándo usar Regresión Logística?

✅ Casos Ideales:

- Necesitas **explicar** las decisiones (regulación, auditoría)
- Tienes **relaciones aproximadamente lineales** con el log-odds
- Quieres un **baseline sólido** antes de probar modelos complejos
- Datos con **pocas no-linealidades**

❌ Evitar cuando:

- Relaciones muy complejas/no-lineales
- Muchas interacciones entre variables
- Imágenes, texto, series temporales complejas
- Necesitas el máximo rendimiento (usa XGBoost)

Para Profundizar: Lecturas Recomendadas

Teoría Matemática:

- Agresti, A. (2013). *Categorical Data Analysis* (3rd ed.). Wiley.
- McCullagh, P., & Nelder, J. A. (1989). *Generalized Linear Models* (2nd ed.). Chapman & Hall.

Aplicaciones en Riesgo Crediticio:

- Siddiqi, N. (2017). *Intelligent Credit Scoring* (2nd ed.). Wiley.
- Thomas, L. C. (2009). *Consumer Credit Models*. Oxford University Press.

Papers Fundacionales:

- Cox, D. R. (1958). The regression analysis of binary sequences. *Journal of the Royal Statistical Society, Series B*, 20(2), 215–242.



15 minutos


BLOQUE 5

Validación Honesta: CV y Sesgo-Varianza

Validación Cruzada (Cross-Validation)

"Un solo train/test puede mentir por suerte. La validación cruzada promedia varias particiones."


Validación cruzada ($k = 5$): cada bloque es validación una vez



Sesgo vs Varianza: el equilibrio clave

- **Subajuste (alto sesgo):** el modelo es demasiado simple, falla en train y test.
- **Sobreajuste (alta varianza):** memoriza el train, falla en test.
- **Punto óptimo:** el menor error de validación.

El anti-pattern "evaluar en train" esconde la varianza: en train siempre mejora, en validación se paga.



Train / Validation / Test: tres conjuntos

Conjunto	Para qué	Regla
Train	Aprender los parámetros (β)	El modelo lo "ve"
Validation	Elegir hiperparámetros / modelo	Se usa muchas veces → puede sesgarse
Test	Estimar el desempeño final	Se toca una sola vez , al final

```
# Validation se obtiene vía Cross-Validation sobre el train.  
# El test se reserva intacto hasta el final.  
X_train, X_test, y_train, y_test = train_test_split(  
    X, y, test_size=0.2, stratify=y, random_state=42)
```

Para datos con fecha: usa **TimeSeriesSplit** (validación *out-of-time*), nunca un split al azar.



BLOQUE 6

Data Leakage y Hands-On



¿Qué es Data Leakage?

"Cuando el modelo 'hace trampa' usando información que no estaría disponible en el momento de la predicción real."

Tipos de Leakage:


Tipo	Ejemplo	Consecuencia
Target Leakage	Usar "Estado del Préstamo" para predecir default	El target está codificado en los features
Train-Test Contamination	Calcular la media con todo el dataset	El modelo "ve" el futuro
Temporal Leakage	Usar datos de Julio para predecir Junio	Información del futuro

🔍 Síntomas de Data Leakage

🚩 Red Flags:

1. Accuracy sospechosamente alto (>95% en problemas reales)
2. Una variable domina (importancia > 80%)
3. "Perfecto" en test, falla en producción
4. La variable parece "demasiado predictiva"

Ej: `dias_desde_ultimo_pago` ≥ 90 para morosos. Pero el atraso **ES** la mora → Target Leakage.



Cómo Prevenir el Leakage

Reglas de Oro:

1. Split PRIMERO, procesa DESPUÉS:

```
#  CORRECTO
X_train, X_test = train_test_split(X, y)
scaler.fit(X_train)           # aprende SOLO del train
X_train_scaled = scaler.transform(X_train)
X_test_scaled = scaler.transform(X_test)
```

2. Usa Pipelines (encapsulan el fit solo en train)

3. Pregúntate: "*¿Esta variable existiría en el momento de la decisión?*"

4. Validación Temporal para datos con fechas (TimeSeriesSplit)


Checklist Anti-Leakage

- [] ¿Hice el split ANTES de cualquier preprocesamiento?
- [] ¿Cada variable existiría en el momento de predicción real?
- [] ¿Ninguna variable está derivada del target?
- [] ¿Mi accuracy es "demasiado bueno para ser verdad"?
- [] ¿Usé Pipeline de scikit-learn para encapsular el fit?
- [] ¿Validé con datos temporalmente posteriores (si aplica)?

 Kaufman, S., Rosset, S., & Perlich, C. (2012). Leakage in data mining: Formulation, detection, and avoidance. *ACM TKDD*, 6(4), 1–21.

Objetivo del Taller

Construir un Pipeline completo para **Credit Scoring**:



Notebooks disponibles:

-  `02_Pipelines_y_Baselines.ipynb` → Versión Profesor (Completa)
-  `02_Pipelines_y_Baselines_Alumnos.ipynb` → Versión Alumnos (Ejercicios)



Checklist del Pipeline Completo

- [] 1. Cargar datos con `load_data()` centralizado
- [] 2. Definir constantes (`TARGET_COL` , `COLS_TO_DROP` , `RANDOM_STATE`)
- [] 3. Split estratificado ANTES de tocar los datos
- [] 4. Identificar tipos (numéricas vs categóricas automáticamente)
- [] 5. Pipeline numérico (Imputer + Scaler)
- [] 6. Pipeline categórico (Imputer + Encoder)
- [] 7. ColumnTransformer (Unir ambos pipelines)
- [] 8. Pipeline final (Preprocessor + Modelo)
- [] 9. Entrenar y evaluar en datos de TEST
- [] 10. Serializar con `joblib.dump()`

Resumen de la Sesión

Hoy aprendimos:

1.  **El mapa completo:** anatomía de un proyecto y de un algoritmo.
2.  **EDA y calidad de datos:** distribuciones, correlación, tipos de faltantes.
3.  **Los 6 Anti-Patterns y Pipelines** robustos (+ feature engineering, encoding, escalado).
4.  **Regresión Lineal y Logística** con la plantilla (intuición → métricas → condiciones).
5.  **Validación honesta:** cross-validation y sesgo-varianza.
6.  **Data Leakage** y cómo prevenirlo.

Próxima sesión (Sesión 02):

 **Árboles de Decisión, Random Forest y Gradient Boosting (XGBoost/LightGBM)**

Referencias Completas

- Agresti, A. (2013). *Categorical Data Analysis* (3rd ed.). Wiley.
- Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer.
- Burkov, A. (2020). *Machine Learning Engineering*. True Positive Inc.
- Cox, D. R. (1958). The regression analysis of binary sequences. *Journal of the Royal Statistical Society, Series B*, 20(2), 215–242.
- Géron, A. (2022). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow* (3rd ed.). O'Reilly Media.
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning* (2nd ed.). Springer.
- Hosmer, D. W., Lemeshow, S., & Sturdivant, R. X. (2013). *Applied Logistic Regression* (3rd ed.). Wiley.
- Kaufman, S., Rosset, S., & Perlich, C. (2012). Leakage in data mining. *ACM TKDD*, 6(4), 1–21.
- Molnar, C. (2022). *Interpretable Machine Learning* (2nd ed.). Leanpub.
- Provost, F., & Fawcett, T. (2013). *Data Science for Business*. O'Reilly Media.
- Sculley, D. et al. (2015). Hidden technical debt in ML systems. *NeurIPS*, 28.
- Siddiqi, N. (2017). *Intelligent Credit Scoring* (2nd ed.). Wiley.
- Thakur, A. (2020). *Approaching (Almost) Any Machine Learning Problem*. Amazon.
- Zheng, A., & Casari, A. (2018). *Feature Engineering for Machine Learning*. O'Reilly Media.

¿Preguntas?

 jrodriguezm216@gmail.com

 jordandataexpert.com

 github.com/JordanKingPeru

 ¡Vamos al Código!

Abrir: `notebooks/02_Pipelines_y_Baselines_Alumnos.ipynb`