

Programa de Especialización en Ciencia de Datos — UNI

Documento de Validación de Modelo de Riesgo de Crédito

Scorecard de probabilidad de incumplimiento (PD) y modelo challenger de Machine Learning

Caso integrador end-to-end — Aprendizaje Supervisado

Control del documento

Campo	Detalle
Título	Validación de Modelo de Riesgo de Crédito — Scorecard PD
Tipo de modelo	Calificación crediticia (probabilidad de incumplimiento a 1 período)
Marco de referencia	Gestión de riesgo de crédito y de modelos — lineamientos SBS (Perú)
Cartera	Tarjetas de crédito — personas naturales
Estado	Validación independiente
Clasificación	Confidencial
Versión	1.0
Audiencia	Comité de Riesgos · Validación de Modelos · Regulador

Aviso. Documento de carácter técnico y formativo. Los datos provienen de la base pública *Default of Credit Card Clients* (UCI, Taiwán; 30.000 clientes), utilizada como sustituto realista de una cartera supervisada. La terminología regulatoria (clasificación del deudor, provisiones, estabilidad PSI, backtesting) sigue los lineamientos de la SBS con fines ilustrativos.

Resumen ejecutivo

Este documento presenta el desarrollo y la **validación independiente** de un modelo de calificación crediticia (PD) para una cartera de tarjetas de crédito de personas naturales. Se construyen dos modelos:

1. **Modelo regulatorio (en producción):** un **scorecard** basado en *Weight of Evidence* (WoE) y regresión logística. Es transparente, auditable y traducible a puntajes — requisito para su uso en decisiones de crédito y para la revisión del supervisor.
2. **Modelo challenger:** un **Gradient Boosting (LightGBM)** optimizado con Optuna y explicado con **SHAP**. Establece la cota superior de poder predictivo y permite cuantificar cuánto desempeño se sacrifica por interpretabilidad.

El documento recorre **todo el ciclo de vida del modelo**: datos y diccionario, análisis exploratorio, definición del *target*, matriz de variables (IV/WoE), entrenamiento, diagnóstico de sesgo-varianza, optimización de hiperparámetros, desempeño (ROC, KS, Gini, calibración), **estabilidad en el tiempo (PSI)** y **traducción a impacto de negocio** (curvas de ganancia, deciles y estimación financiera).

Los indicadores numéricos de este resumen se calculan automáticamente al final del documento (sección 12) a partir de la ejecución real del modelo.

0. Configuración del entorno y tema visual

Se define **una sola vez** la paleta corporativa y el tema de los gráficos, de modo que todas las figuras del documento compartan la misma estética (requisito de un entregable profesional).

Entorno configurado. Tema corporativo activo. Semilla = 42

1. Contexto y datos

Objetivo del modelo. Estimar la probabilidad de que un cliente de tarjeta de crédito **incumpla su pago en el siguiente período** (PD a 1 mes), para soportar decisiones de admisión, líneas y provisiones bajo los lineamientos de gestión de riesgo de crédito de la SBS.

Fuente. *Default of Credit Card Clients* (UCI Machine Learning Repository, Taiwán). 30.000 clientes, 23 variables predictoras y la variable objetivo `default` (1 = incumple el próximo mes).

Clientes: 30,000 | Variables: 26 | Tasa de default: 22.12%

	LIMIT_BAL	SEX	EDUCATION	MARRIAGE	AGE	PAY_1	PAY_2	PAY_3	PAY_4	PAY_5
0	20000	2	2	1	24	2	2	-1	-1	-1
1	120000	2	2	2	26	-1	2	0	0	0
2	90000	2	2	2	34	0	0	0	0	0
3	50000	2	2	1	37	0	0	0	0	0
4	50000	1	2	1	57	-1	0	-1	0	0

5 rows × 27 columns




Diccionario de variables

Variable	Descripción	Tipo
LIMIT_BAL	Línea de crédito otorgada (NT\$)	Numérica
SEX	Sexo (1=hombre, 2=mujer)	Categórica
EDUCATION	Nivel educativo (1=posgrado ... 4=otros)	Categórica
MARRIAGE	Estado civil (1=casado, 2=soltero, 3=otros)	Categórica
AGE	Edad (años)	Numérica
PAY_1 ... PAY_6	Estado de pago últimos 6 meses (-1=al día, ≥1=meses de atraso)	Ordinal
BILL_AMT1 ... 6	Monto facturado últimos 6 meses (NT\$)	Numérica
PAY_AMT1 ... 6	Monto pagado últimos 6 meses (NT\$)	Numérica
UTILIZACION	Facturación / línea (derivada)	Numérica
PAGO_RATIO	Pago / facturación (derivada)	Numérica
MESES_ATRASO_MAX	Máximo atraso en 6 meses (derivada)	Numérica
default	Objetivo: 1 = incumple el próximo mes	Binaria

3. Análisis exploratorio (EDA)

Antes de modelar se revisa la distribución de las variables clave, la completitud de la información y la estructura de correlaciones. El objetivo es detectar anomalías, concentraciones y relaciones que condicionen el diseño del scorecard.

Figura 3.1 — Perfil descriptivo de la cartera
Distribución de la línea de crédito




4. Construcción y análisis del *target*

La variable objetivo `default` indica incumplimiento en el siguiente período. Se analiza el **balance de clases** (clave para elegir métricas) y la **tasa de evento por segmento**, que anticipa qué variables tendrán poder discriminante.


Balance de clases

Tasa de incumplimiento = 22.1%



Tasa de incumplimiento por decil de utilización

% que incumple



5. Matriz de variables: Weight of Evidence (WoE) e Information Value (IV)

En un scorecard regulatorio cada variable se transforma a **WoE** (logaritmo del cociente entre la proporción de buenos y malos en cada tramo) y se prioriza por su **Information Value (IV)**, indicador estándar de poder predictivo:

IV	Poder predictivo
< 0,02	Nulo
0,02 – 0,1	Débil
0,1 – 0,3	Medio
0,3 – 0,5	Fuerte
> 0,5	Sospechoso (revisar)

El binning óptimo (monótono) se calcula con `optbinning`, estándar de la industria para scorecards.

	name	iv	js	quality_score	poder
0	PAY_1	0.879211	0.098011	0.161188	Sospechoso
1	MESES_ATRASO_MAX	0.779386	0.093554	0.279752	Sospechoso
2	PAY_2	0.557144	0.064793	0.260428	Sospechoso
3	PAY_3	0.419835	0.04944	0.748625	Fuerte
4	PAY_4	0.367989	0.043082	0.743552	Fuerte
5	PAY_5	0.342765	0.039685	0.695378	Fuerte
6	PAY_6	0.295911	0.034716	0.691733	Medio
7	LIMIT_BAL	0.200189	0.024597	0.153087	Medio
8	PAY_AMT1	0.182789	0.022386	0.438066	Medio
9	PAGO_RATIO	0.118756	0.014674	0.085327	Medio
10	UTILIZACION	0.090687	0.011227	0.217185	Débil
11	EDUCATION	0.021425	0.002675	0.063572	Débil
12	AGE	0.02018	0.002517	0.000132	Débil
13	SEX	0.010423	0.001302	0.027698	Nulo
14	BILL_AMT1	0.009387	0.001172	0.00032	Nulo
15	MARRIAGE	0.004495	0.000562	0.012427	Nulo

Figura 5.1 — Information Value por variable





Figura 5.2 — Patrón WoE de las variables líderes



6. Entrenamiento de los modelos

Se entrenan dos modelos sobre la misma partición:


- **Scorecard (regulatorio):** `optbinning.Scorecard` = binning WoE + **regresión logística**. Es el modelo candidato a producción por su transparencia.
- **Challenger: LightGBM** (Gradient Boosting), que captura no linealidades e interacciones.

La **curva de aprendizaje** del challenger permite juzgar si el volumen de datos es suficiente.

AUC Scorecard (regulatorio): 0.7613

AUC LightGBM (challenger): 0.7771


Figura 6.1 — Curva de aprendizaje (AUC) del challenger



7. Diagnóstico de sesgo y varianza

Se contrasta el desempeño en entrenamiento y validación para distintas **profundidades** del challenger. Una brecha pequeña con AUC alto indica buen balance; una brecha grande señala **sobreajuste** (varianza); un AUC bajo en ambos, **subajuste** (sesgo).

Figura 7.1 — Trade-off sesgo-varianza



8. Optimización de hiperparámetros (Optuna)


Se calibra el challenger con **búsqueda bayesiana** (Optuna), maximizando el AUC en validación cruzada estratificada. Se reportan la trayectoria de la optimización y la importancia de cada hiperparámetro.

Mejor AUC en validación cruzada: 0.7854

Hiperparámetros óptimos:

- `n_estimators` : 500
- `learning_rate` : 0.0123
- `num_leaves` : 35
- `max_depth` : 4
- `min_child_samples` : 73
- `subsample` : 0.9115
- `colsample_bytree` : 0.7757

Figura 8.1 — Optimización de hiperparámetros




9. Desempeño y poder discriminante

Se evalúa el poder de ambos modelos con las métricas estándar de un modelo de admisión:

ROC/AUC, **KS** (máxima separación entre acumulados de buenos y malos), **Gini** ($= 2 \cdot \text{AUC} - 1$), **matriz de confusión** al punto de corte de negocio y **calibración** (¿las PD predichas coinciden con las observadas?). Para el scorecard se muestra además la **separación de puntajes**.

Modelo	AUC	Gini	KS
Scorecard (regulatorio)	0.7613	0.5227	0.3967
LightGBM (challenger)	0.7818	0.5637	0.4200


Figura 9.1 — Diagnóstico de desempeño



9.1 Explicabilidad del challenger (SHAP)

Para que el modelo de mayor poder no sea una "caja negra", se explica con **valores SHAP**: el aporte de cada variable a la predicción. Es el puente entre el poder del ML y la **trazabilidad** que exige el supervisor.

Figura 9.2 — Importancia global de variables (SHAP)




10. Estabilidad en el tiempo (PSI)

El **Population Stability Index (PSI)** mide cuánto se desplaza la distribución del score entre el período de **desarrollo** y el de **monitoreo**. Es la prueba central del seguimiento regulatorio:

PSI	Interpretación (SBS / industria)
< 0,10	Población estable
0,10 – 0,25	Cambio moderado — observar
> 0,25	Cambio significativo — recalibrar / redesarrollar

Como sustituto de cohortes temporales, se compara la distribución del score de desarrollo (train) contra la de monitoreo (test), y se proyecta un seguimiento mensual con ventanas del período de prueba.

Figura 10.1 — Estabilidad poblacional (PSI)



11. Traducción a impacto de negocio

El desempeño estadístico se convierte en lenguaje de negocio: **curva de ganancia (gains/lift)**, tasa de incumplimiento por **decil de riesgo** y una **estimación financiera** de la política de corte (aprobar solo por debajo de un score de riesgo), comparando contra la situación sin modelo.

Figura 11.1 — Poder de ordenamiento para negocio





Figura 11.2 — Impacto financiero de la política de corte

Aprobando el 70% de menor riesgo · mejora vs sin modelo: 4,542 u.



Resultado con modelo: 1,596 | sin modelo: -2,946 | mejora: 4,542

=====
TABLERO DE INDICADORES — MODELO DE RIESGO DE CRÉDITO
=====

	Indicador	Valor
0	AUC scorecard	0.7613
1	Gini scorecard	0.5227
2	KS scorecard	0.3967
3	AUC challenger (LightGBM)	0.7818
4	Gini challenger	0.5637
5	PSI desarrollo→monitoreo	0.0020
6	Mejora financiera vs sin modelo (u.)	4542.0000

12. Conclusiones, recomendaciones y anexos

Conclusiones

- El **scorecard WoE + logística** ofrece un poder discriminante adecuado (ver tablero de indicadores) con **plena interpretabilidad**: cada decisión se descompone en puntajes por variable, condición necesaria para su aprobación regulatoria y para la atención de reclamos.
- El **challenger LightGBM** mejora el AUC/Gini, cuantificando el costo de oportunidad de mantener un modelo lineal. SHAP provee la trazabilidad que mitiga el riesgo de "caja negra".

- La población es **estable** en el horizonte analizado (PSI dentro de umbral), por lo que no se gatilla recalibración inmediata; se fija monitoreo mensual de PSI con alertas en 0,10 y 0,25.
- La política de corte propuesta genera una **mejora financiera** frente a no usar modelo, capturando la mayor parte de los incumplimientos en los primeros deciles de riesgo.

Recomendaciones (marco SBS)

1. **Gobierno del modelo:** validación independiente anual y backtesting trimestral de PD vs observado.
2. **Monitoreo:** tablero mensual de PSI (score y variables top), KS y tasa de aprobación.
3. **Uso dual:** scorecard en producción para la decisión; challenger como referencia de mejora y para priorizar el próximo desarrollo.
4. **Provisiones:** mapear la PD a las categorías de clasificación del deudor y al cálculo de provisiones.

Anexo A — Glosario

PD: probabilidad de incumplimiento. **WoE:** Weight of Evidence. **IV:** Information Value. **KS:** estadístico de Kolmogorov–Smirnov. **Gini** = $2 \cdot \text{AUC} - 1$. **PSI:** Population Stability Index. **Scorecard:** modelo de puntajes derivado de WoE + logística. **Challenger:** modelo alternativo de mayor poder usado como referencia.

Anexo B — Control de versiones

Versión	Cambios	Estado
1.0	Desarrollo inicial y validación independiente	Vigente

Anexo C — Reproducibilidad

Datos: UCI *Default of Credit Card Clients* (id=350), descargados con `ucimlrepo`. Entorno: `requirements.txt` del curso + `optbinning`. Semilla global fija. Notebook generado por `build_reporte.py`.